

PyGeek 2026 구두발표 대본 — 윤준하

대상 파일: docs/reference/PyGeek2026_발표_윤준하_rev7.pptx (16장 · 영문 슬라이드)
일시: 2026-08-20(목) 14:10-14:30 · Oral Presentation #1 · 홍익대 와우관 2층
슬롯 20분 = 발표 15분 + Q&A 4분 + 교체 1분 · 발표 언어: 한국어

시간 배분표

장	쪽	슬라이드	구간	배정
1	—	Title	0:00-0:35	35초
2	1	Contents	0:35-0:55	20초
3	2	Introduction — 벡터 레이어	0:55-1:45	50초
4	3	Introduction — 두 요인 ★	1:45-3:05	80초
5	4	Introduction — 오진단	3:05-4:05	60초
6	5	Proposed Method — 브리지 ★★	4:05-5:45	100초
7	6	Proposed Method — 시스템 구조	5:45-6:40	55초
8	7	Performance Evaluation	6:40-7:30	50초
9	8	Experiment Result — 저장소 ★	7:30-8:40	70초
10	9	Experiment Result — 지표 해설 ①	8:40-9:20	40초
11	10	Experiment Result — 위치 ★	9:20-10:45	85초
12	11	Experiment Result — 지표 해설 ②	10:45-11:15	30초
13	12	Experiment Result — 등가성	11:15-12:35	80초
14	13	Conclusion ★	12:35-14:25	110초
15	14	References	14:25-14:35	10초
16	15	Thank You	14:35-14:50	15초

중간 점검: 슬라이드 8(Performance Evaluation)을 넘길 때 **7분 30초**면 정상. 8분 30초가 넘었으면 아래 <생략 가능>을 버린다.

1

Title

0:00-0:35

안녕하십니까. 성결대학교 윤준하입니다.

발표에 앞서 좋은 자리를 마련해 주신 조직위원회와 좌장님께 감사드립니다.

제가 발표드릴 논문은 「벡터 데이터베이스 이전에서, 저장소 교체와 임베딩 위치 효과를 분리하는 요인 분해 방법」입니다.

슬라이드는 영문으로 준비했고, 발표는 한국어로 진행하겠습니다.

발표는 다섯 부분으로 진행하겠습니다.

먼저 **어떤 문제가 있는지** 말씀드리고, 그 문제를 가려내기 위해 저희가 **제안하는 방법**을 설명드리겠습니다.

이어서 **실험 설정과 결과**를 보여 드리고, **결론**으로 마무리하겠습니다.

3 Introduction — 벡터 레이어

0:55-1:45

배경을 간단히 말씀드리겠습니다.

RAG 시스템은 크게 세 요소로 이루어집니다. 질의와 문서를 벡터로 바꾸는 **임베딩 모델**, 그 벡터를 색인하고 검색하는 **저장소**, 그리고 찾아온 근거로 답을 만드는 **언어 모델**입니다.

(그림 위쪽을 짚으며) 이 가운데 가운데 두 요소, 즉 **벡터 레이어가 배포 이후에 가장 자주 바뀌는 부분**입니다.

(그림 아래쪽을 짚으며) 대표적인 경로는 이렇습니다. 벡터 확장을 엮은 범용 관계형 데이터베이스에서, 벡터 타입과 추론 런타임을 내장한 융합형 데이터베이스로 옮겨 가는 경우입니다. 다시 말해 **데이터베이스가 임베딩 계산까지 직접 수행하게 됩니다**.

4 Introduction — 두 요인 ★

1:45-3:05

바로 여기서 문제가 생깁니다.

이전 한 번에 **두 가지 요인이 함께 접혀 들어갑니다**.

첫째는 **저장소**입니다. 벡터를 담고 있는 엔진과 그 인덱싱 방식, 즉 근사 검색이나 정확 검색이냐가 여기에 해당합니다.

둘째는 **임베딩 위치**입니다. 임베딩 계산을 데이터베이스 바깥에서 하느냐, 안에서 하느냐입니다.

(그림의 붉은 두 줄을 짚으며) 화면에서 보시는 것처럼, 이전 전후에 실제로 달라지는 항목이 이 두 가지입니다.

그런데 이 둘이 함께 바뀌는 데에는 이유가 있습니다.

데이터 거버넌스를 이유로 이전을 결정하면, 질의 경로까지 경계 안으로 들이고 싶어집니다. 그래서 임베딩도 자연스럽게 안으로 옮기게 됩니다.

그리고 데이터베이스 안에서 모델을 돌리려면 **모델 크기 제한**을 받습니다. 그래서 위치를 옮기는 순간 모델 용량까지 딸려서 바뀝니다.

결국 전후 차이 하나만 가지고는, 달라진 원인이 어느 쪽인지 지목할 수가 없습니다.

그러면 이것이 왜 실무에서 문제가 되는지 말씀드리겠습니다.

(왼쪽 상자) **품질이 떨어졌을 때**, 저장소 타인지 모델 타인지 구분이 되지 않습니다.

(오른쪽 상자) **아무 변화가 없을 때**도 마찬가지입니다. 정말로 효과가 없었던 것인지, 아니면 두 요인이 서로 상쇄된 것인지 알 수가 없습니다.

두 경우 모두 **구분이 안 된다는 결론에 똑같이 도달합니다.**

그래서 처방이 어긋납니다. 저장소를 원인으로 지목하고 되돌리더라도 품질은 돌아오지 않습니다.

<생략 가능> 그리고 이렇게 내린 결론은 인스턴스 등급이나 모델 크기 제한이 다른 환경으로 옮겨 적용할 수도 없습니다.

6 Proposed Method — 브리지 조건 ★★

4:05-5:45

이 발표의 핵심입니다. 여기서 한 번 호흡을 두고, 그림을 짚으면서 천천히 갑니다.

그래서 저희가 제안드리는 것이 **브리지 조건**입니다.

아이디어 자체는 단순합니다. **원본 시스템이 이미 만들어 둔 벡터를, 그대로 목표 저장소에 실어 올립니다.** 화면 가운데 있는 조건 B가 그것입니다.

이렇게 하면 조건 B는 저장소만 목표 시스템이고, 임베딩 모델과 임베딩 위치는 원본과 똑같은 상태가 됩니다.

그 결과 (왼쪽 화살표를 가리키며) **A에서 B로 갈 때는 저장소만 달라지고**, (오른쪽 화살표를 가리키며) **B에서 C로 갈 때는 위치만 달라집니다.** 한 번에 한 요인씩 보게 되는 것입니다.

이 조건의 실무적인 장점을 하나 말씀드리고 싶습니다. **벡터를 다시 만들 필요가 없습니다.** 이미 가지고 있는 벡터를 옮겨 심기만 하면 되기 때문에, 임베딩 비용이 추가로 들지 않고 운영 중인 서비스를 멈추지 않아도 됩니다.

이전을 결정하기 **전에** 미리 확인해 볼 수 있는 조건이라는 점이, 저희가 생각하는 이 방법의 쓸모입니다.

7 Proposed Method — 시스템 구조

5:45-6:40

실제로 무엇이 달라지는지를 구조로 보여 드리겠습니다.

(왼쪽) 기존 시스템에서는 애플리케이션이 외부 임베딩 서비스를 호출하고, 그 결과를 다시 저장소로 보냅니다. **네트워크 경계를 두 번 넘습니다.**

(오른쪽) 이전 후에는 임베딩과 검색이 모두 데이터베이스 안에서 일어납니다. **경계는 한 번으로 줄고, 외부 모델 호출은 사라집니다.**

한 가지 말씀드릴 것은, **검색 규칙과 파라미터는 세 조건에서 완전히 동일하게 고정했다는 점입니다.** 벡터 유사도와 메타데이터 필터, 출처 기반 우선순위까지 같게 두었습니다. 비교하려는 요인 외에 다른 것이 섞이지 않도록 하기 위해서입니다.

여기서 7분 30초면 정상 속도입니다.

실험 설정입니다.

대상은 운영 중인 국내 제품 리뷰 분석 서비스의 리뷰 청크 1,347개이고, 고정된 질의 43개로 측정했습니다.

지표는 세 갈래입니다. 검색 결과가 얼마나 일치하는지를 보는 **검색 일치도**, 찾아온 근거가 질의에 얼마나 맞는지를 0점에서 2점으로 매긴 **근거 관련성**, 그리고 **검색 지연 시간**입니다.

(표를 짚으며) 표에서 **파란색으로 칠한 칸이 저장소 요인으로 바뀐 항목**이고, **붉은색으로 칠한 칸이 위치 요인으로 바뀐 항목**입니다. 색이 없는 칸은 그대로 넘어온 항목입니다.

<생략 가능> 신뢰구간은 부트스트랩 1만 회 재표집으로 구했고, 목표 데이터베이스는 최저 등급 인스턴스에서 구동했습니다.

9 Experiment Result — 저장소 요인 ★

7:30-8:40

첫 번째 결과입니다. **저장소만 바꾼 A에서 B 구간**입니다.

상위 10개 결과의 자카드 유사도가 **0.971**이었습니다. 신뢰구간은 0.946에서 0.992입니다.

근거 관련성의 p값은 **0.523**으로 유의하지 않았고, 효과 크기는 0.098로 무시할 수 있는 수준입니다.

풀어서 말씀드리면, **동일한 벡터를 실었을 때 두 저장소는 43개 질의 가운데 37개에서 상위 10개 집합이 정확히 같았습니다.**

기준 시스템이 근사 인덱스를 쓰기 때문에 놓친 부분이 있는데, 그 크기가 대략 1.6퍼센트 정도였습니다.

<생략 가능> 동점을 제외하고 남은 질의만으로 월콕슨 검정을 해 보아도 결론은 같았습니다. p값 0.908입니다.

10 Experiment Result — 지표 해설 ①

8:40-9:20

숫자가 익숙하지 않으실 수 있어 잠시 지표를 설명드리겠습니다.

(왼쪽) **자카드 유사도**는 두 결과 집합이 얼마나 겹치는지를 0에서 1 사이로 나타낸 값입니다. 보시는 것처럼 A와 B가 같은 목록을 가져왔기 때문에 1에 가깝게 나옵니다.

(오른쪽) **p값**은 관측된 차이가 우연히 생겼을 확률로 이해하시면 됩니다. 관측값이 우연 분포의 한가운데에 있어서, 우연으로 충분히 설명이 됩니다.

이 두 지표를 다음 장에서 위치 요인에 그대로 적용해 보겠습니다.

두 번째 결과입니다. 위치만 바꾼 B에서 C 구간입니다.

같은 자카드 유사도가 0.175로 떨어졌습니다. 앞에서 0.971이었던 값입니다.

p값은 0.003으로 유의했고, 효과 크기는 0.473, 중간 크기입니다.

여기서 강조드리고 싶은 것은, 저장소도 같고 검색 방식도 같은데 같은 질의에 대해 대체로 다른 근거가 돌아왔다는 점입니다.

그리고 앞 구간에서 저장소 효과가 검출되지 않았기 때문에, 관측된 품질 변화는 사실상 전부 위치 요인과 거기에 달려 온 모델 크기 제한에서 비롯되었다고 볼 수 있습니다.

여기서 한 박자 쉬고, 청중을 보며 말합니다.

만약 전후 비교만 했다면 어땠을까요. 관련성이 떨어진 것을 저장소 탓으로 돌렸을 것입니다. 그리고 저장소를 되돌렸겠지 만, 품질은 돌아오지 않았을 것입니다.

12 Experiment Result — 지표 해설 ②

10:45-11:15

같은 두 지표를 위치 요인에 그대로 적용한 그림입니다.

(왼쪽) 자카드는 0.971에서 0.175로 떨어졌습니다. 두 목록을 합치면 17개인데 그 가운데 겹치는 것은 3개뿐입니다.

(오른쪽) p값은 0.523에서 0.003으로 내려가, 관측값이 우연 분포의 바깥쪽 꼬리에 놓입니다.

같은 잣대를 두 구간에 똑같이 댔을 때 이만큼 다른 그림이 나온다는 것이 이 방법의 요점입니다.

13 Experiment Result — 등가성 검정

11:15-12:35

여기서 한 가지 조심스럽게 말씀드릴 부분이 있습니다.

앞서 저장소 요인의 p값이 유의하지 않다고 말씀드렸습니다. 그런데 유의하지 않은 p값은 차이가 없다는 증거가 아닙니다. 검출하지 못했다는 것과 없다는 것은 다릅니다.

그래서 저희는 등가성 검정을 따로 수행했습니다. 플러스마이너스 0.15점 범위를 두고 TOST를 적용했습니다.

(그림의 파란 띠를 짚으며) 화면의 열은 띠가 저희가 설정한 그 범위입니다. 신뢰구간이 이 띠 안에 완전히 들어가야 등가성을 주장할 수 있는데, 보시는 것처럼 왼쪽 끝이 띠 밖으로 조금 나가 있습니다.

결과는 p값 0.052로, 유의수준을 충족하지 못했습니다.

그래서 저희는 이렇게 보고합니다. "등가성이 입증되었다"가 아니라, "효과가 검출되지 않았고, 그 크기가 작은 범위 안으로 제한된다"입니다.

다만 구간이 뻗어 있는 방향은 목표 저장소 쪽 점수가 더 높은 방향입니다. 따라서 저장소를 교체해서 품질이 나빠졌다고 볼 근거는 없습니다.

결론과 한계를 한 장에서 이어 말합니다. 앞부분에서 한 번, 각주로 내려갈 때 한 번 호흡을 돕니다.

정리하겠습니다.

방법 면에서는, 중간 조건 하나를 더하는 것만으로 전후 비교 한 번이 단일 요인 비교 두 번으로 나뉩니다.

이 서비스에서 관측한 것은, 저장소 요인의 효과가 검출되지 않았고 관측된 변화가 전부 위치 요인에서 나왔다는 점입니다.

저희가 이 발표에서 드리고 싶은 문장은 이것입니다. **임베딩 위치를 옮기는 것은 성능의 교환이 아니라 거버넌스의 교환입니다.**

실무 판단 기준으로 옮기면 이렇게 됩니다.

저장된 데이터의 거버넌스만이 목적이라면, **저장소만 교체하는 것으로 충분합니다.**

질의 경로까지 경계 안에 두어야 한다면, **이전하기 전에 모델 크기 제한이 충분한지를 먼저 확인하셔야 합니다.** 브리지 조건은 그 확인을 이전 전에 할 수 있게 해 줍니다.

여기서 한 박자 쉬고, 화면 아래 회색 글씨를 가리킵니다.

마지막으로 한계를 분명히 말씀드리겠습니다.

하나의 제품 도메인에서 나온 1,347개 규모의 한국어 코퍼스 하나로 얻은 결과이고, 근거 관련성 채점에 사람 평가자가 참여하지 않았습니다.

측정이 엔트리급 인스턴스에서 이루어졌기 때문에, 지연 시간 수치는 상위 등급 하드웨어로 일반화할 수 없습니다.

그리고 설계상 **위치와 모델 크기가 묶여 있고**, 저장소 결과도 등가성을 입증한 것은 아닙니다.

향후 과제로는, **작은 모델을 데이터베이스 바깥에서 돌리는 네 번째 조건을** 두어 위치와 모델 크기를 분리하는 것을 생각하고 있습니다.

15 References

14:25-14:35

읽지 않습니다. 화면만 띄우고 한 문장으로 넘깁니다.

본 연구에서 참고한 문헌입니다.

16 Thank You

14:35-14:50

이상으로 발표를 마치겠습니다.

끝까지 들어 주셔서 감사합니다. 질문 주시면 아는 범위에서 성실히 답변드리겠습니다.

예상 질문과 답변

답변은 짧게 시작해서 필요하면 덧붙이는 순서로 갑니다. 모르는 것은 모른다고 말하는 편이 낫습니다.

Q1. 왜 더 큰 임베딩 모델을 쓰지 않았습니까?

데이터베이스 안에서 추론을 수행하려면 그 데이터베이스가 호스팅할 수 있는 모델 크기의 제한을 받습니다. 저희가 쓴 384차원 모델은 그 제한 안에서 고를 수 있었던 선택지였습니다.

그리고 이 제약 자체가 저희 논문이 다루는 대상이기도 합니다. 위치를 안으로 옮기면 모델 용량이 따라온다는 점이 바로 실무에서 문제가 되는 지점이라고 보았습니다.

Q2. 질의 43개는 너무 적지 않습니까?

말씀하신 대로 표본이 크지 않습니다. 한계로 인정합니다.

그래서 저희는 점 추정치만 제시하지 않고 **부트스트랩 신뢰구간과 효과 크기를 함께 보고했고**, 결론도 그 구간 안에서만 이야기하려고 했습니다. 질의 집합을 넓히는 것은 저희도 필요하다고 보고 있습니다.

Q3. 관련성 점수를 사람이 매기지 않은 것은 신뢰할 수 있습니까?

한계로 명시했습니다. 사람 평가자가 참여하지 않았습니다.

다만 채점 기준을 세 조건에 동일하게 적용했기 때문에 **조건 간 비교라는 목적에서는 방향성이 유지된다고 보았습니다**. 절대적인 점수 자체를 주장하려는 것은 아닙니다. 사람 평가를 덧붙이는 것은 다음 과제로 생각하고 있습니다.

Q4. 브리지 조건이라는 것이 새로운 방법입니까?

구성 요소 자체가 새롭다고 말씀드리기는 어렵습니다. 벡터를 옮겨 심는 것도, 요인을 하나씩 바꿔 보는 것도 익숙한 방식입니다.

저희가 기여라고 생각하는 부분은, **벡터 데이터베이스 이전이라는 구체적인 의사결정 상황에서 이것을 하나의 절차로 정리하고, 재임베딩 없이 운영 서비스를 멈추지 않고도 수행할 수 있다는 점을 실측으로 보인 것**입니다.

Q5. 그러면 이전을 하지 말라는 뜻입니까?

그런 뜻은 아닙니다.

목적이 저장된 데이터의 거버넌스라면, 저장소만 교체하는 선택으로 충분하다는 것이 저희 결과입니다. 이 경우에는 품질 변화가 검출되지 않았습니다.

질의 경로까지 경계 안에 두고 싶으시다면, **그때는 모델 크기가 충분한지를 먼저 확인하시라**는 것이 저희가 드리는 말씀입니다.

Q6. 근사 검색과 정확 검색의 차이가 결과에 영향을 주지는 않았습니까?

영향이 있었고, 그 크기를 측정했습니다. 기존 시스템은 근사 인덱스를 쓰고 목표 시스템은 정확 검색을 하는데, 그 차이로 기존 시스템이 놓친 부분이 **약 1.6퍼센트** 수준이었습니다.

이 차이를 포함해도 저장소 요인에서는 유의한 품질 변화가 검출되지 않았습니다.

발표 전 확인 사항

- ☐ 점심시간(12:00-13:30)에 강연장에서 파일 이관 + 발표자 도구 가능 여부 확인 (13:30 이후에는 세션이 연속이라 PC를 만질 틈이 없음)
- ☐ USB에 **rev7 발표용 + PDF 백업**
- ☐ 이 대본 A4 출력 (발표자 도구를 못 쓸 경우의 1차 수단)
- ☐ 14:05까지 앞자리 이동
- ☐ 좌장이 교신저자 성함으로 소개할 수 있음 — 첫 문장에서 본인 이름을 분명히 밝힐 것